Modelo de IA para riesgo crediticio: ¿precisión o equidad?

Auditoría y mitigación de sesgos con XGBoost y Fairlearn

Estudiante: Cristian Estiven Rodriguez Benitez

Asignatura: Electiva II: Inteligencia Artificial Avanzada, Unidad 2

Fecha: 9 de noviembre de 2026

El problema y por qué importa

- Clasificación binaria: dado un solicitante de crédito, predecir si incumplirá.
- Dos errores con víctimas distintas: rechazar a un buen pagador daña a la persona; aprobar a un mal pagador daña a la entidad.
- Los datos históricos traen desigualdades que un modelo puede aprender y aplicar a gran escala.
- El Reglamento de IA de la UE clasifica el scoring crediticio como sistema de **alto riesgo**.

Pregunta: ¿puede un modelo de crédito ser preciso y justo a la vez, y cuánto cuesta corregirlo?

Datos: German Credit y un sesgo de partida

- 1.000 solicitudes, 20 atributos (7 numéricos, 13 categóricos).
- 30 % de incumplimiento, sin valores faltantes.
- Atributos protegidos: edad (<25 / ≥25) y sexo.

Datos de 1994 de un banco alemán: la diferencia es un patrón de esta muestra, no una afirmación sobre las personas.

Grupo	n	Incumplimiento
≥ 25 años	851	28,1 %
< 25 años	149	**40,9 %**
Hombres	690	27,7 %
Mujeres	310	**35,2 %**

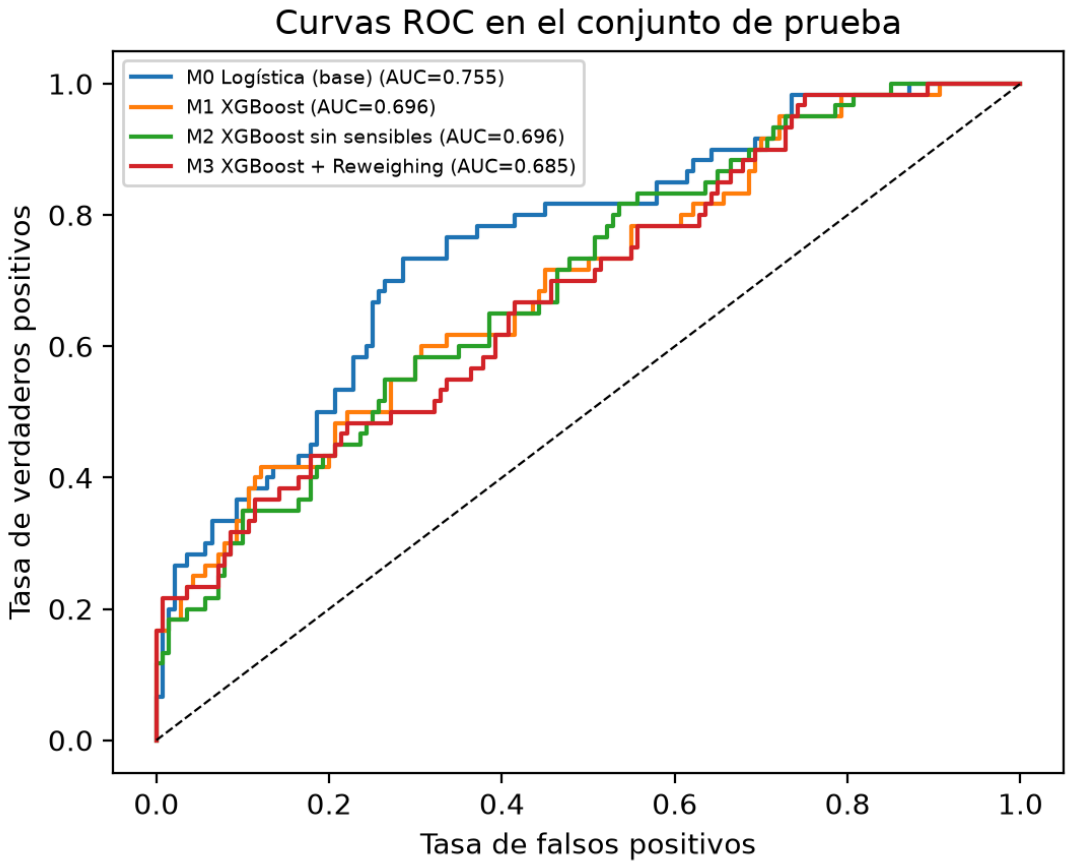
Metodología y modelos

- **Flujo:** imputación, estandarización y one-hot (61 características), ajustado solo con entrenamiento para evitar fuga de datos.
- **Partición estratificada 60 / 20 / 20:** entrenamiento 600, validación 200, prueba 200 (usada una sola vez).
- **M0** regresión logística (línea base) · **M1** XGBoost
- **M2** sin atributos sensibles · **M3** reweighing · **M4** ThresholdOptimizer (equalized odds)
- Búsqueda aleatoria de 60 configuraciones por AUC de validación; umbral que maximiza F1 en validación.

Resultados de desempeño

Modelo	Partición	Recall	F1	AUC
M0 Logística	Train	0,767	0,663	0,845
M0 Logística	Test	0,683	0,599	**0,755**
M1 XGBoost	Train	0,872	0,929	0,997
M1 XGBoost	Test	0,417	0,485	**0,696**

XGBoost se sobreajusta (AUC 0,997 a 0,696) y **no supera** a la línea base en prueba.

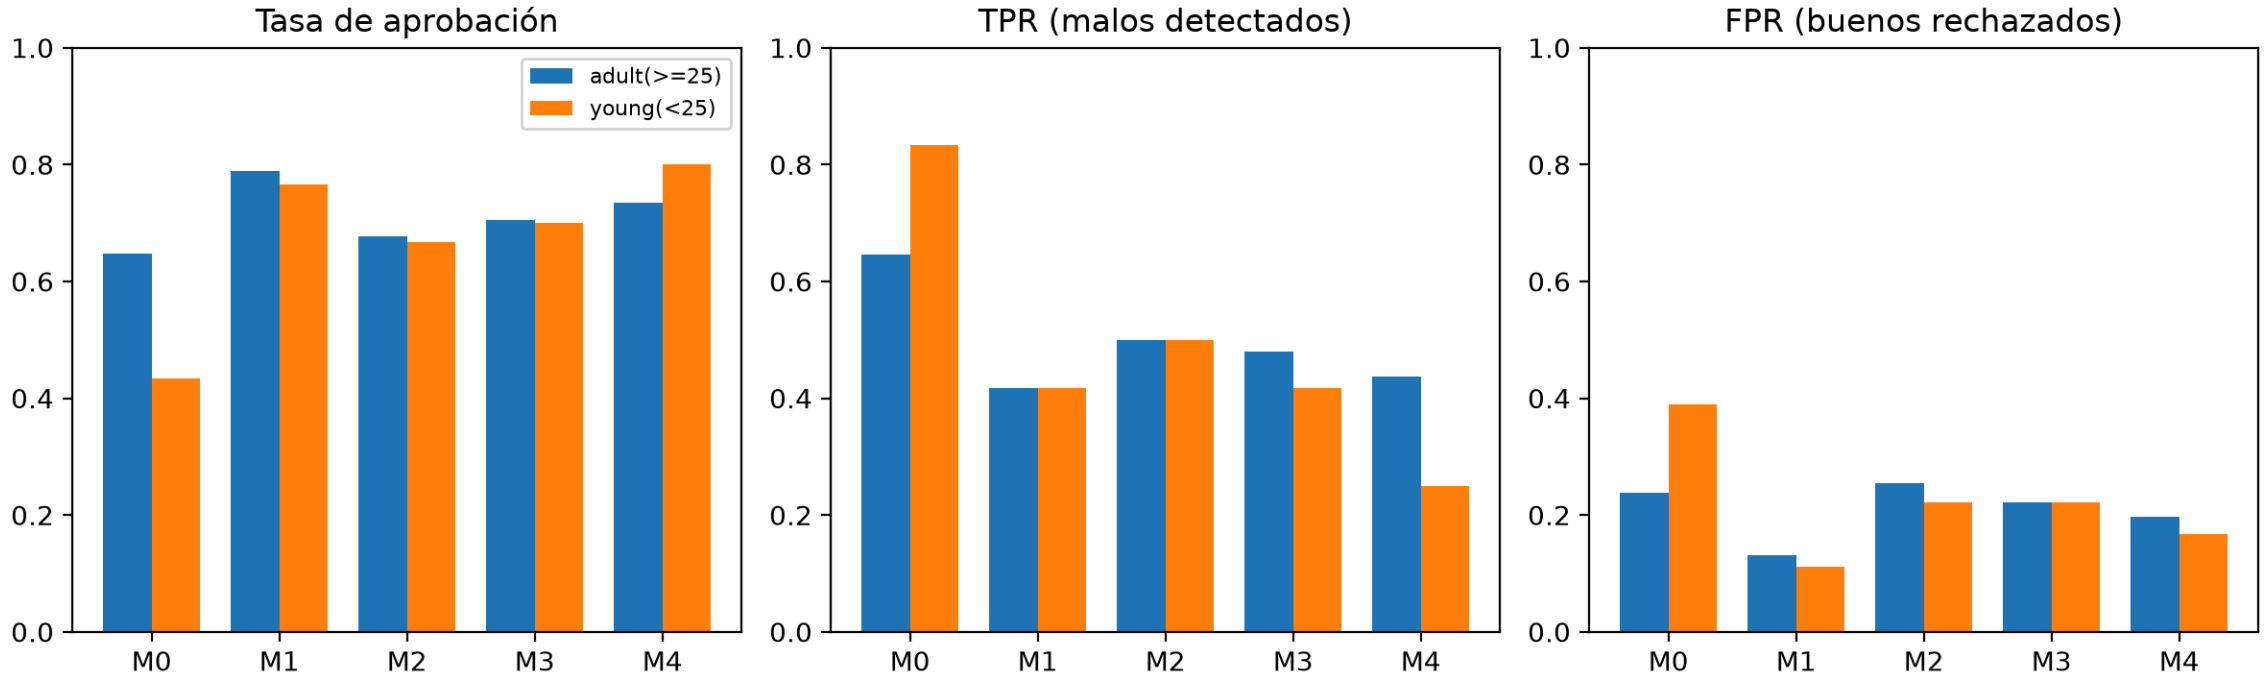


Auditoría de equidad por edad

64,7 %
aprobación ≥ 25 años

43,3 %
aprobación < 25 años

La regresión logística tiene un **impacto dispar de 0,67**: incumple la regla de los cuatro quintos (≥ 0,80). Rechaza a más buenos pagadores jóvenes (FPR 0,39 frente a 0,24).



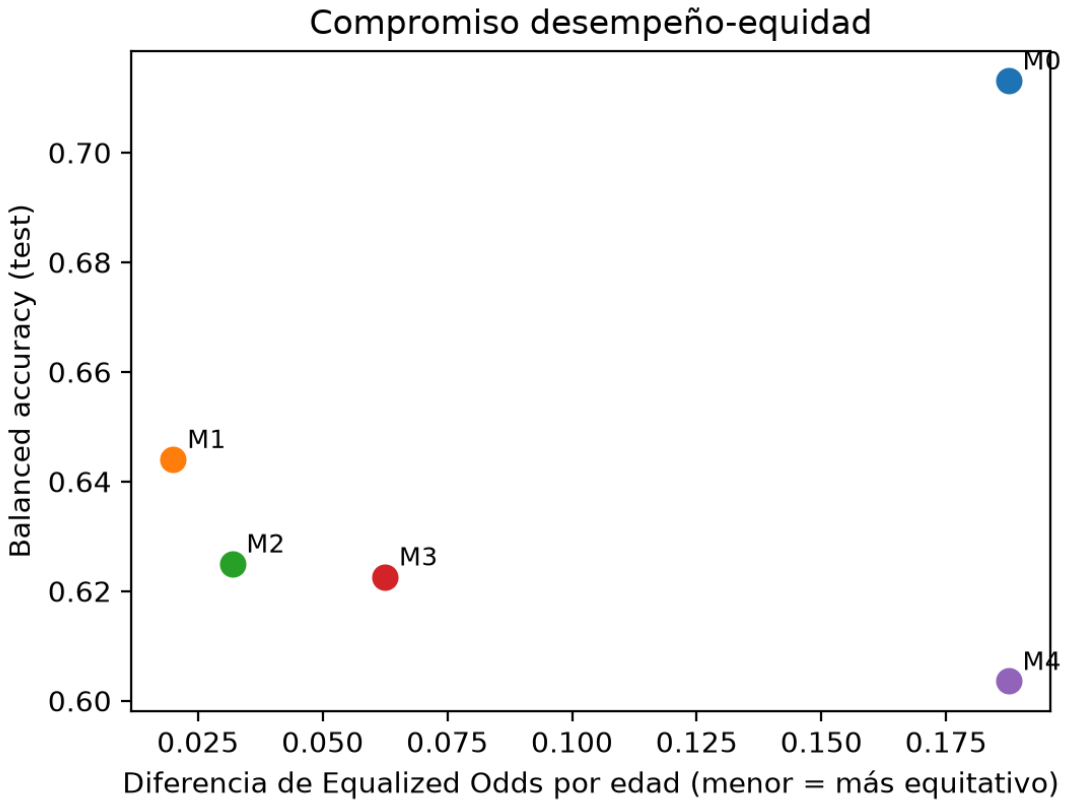
Mitigación de sesgos: lo que cambió

Modelo	F1	AUC	Impacto dispar	EOD edad
M0 Logística	0,599	0,755	0,670	0,188
M1 XGBoost	0,485	0,696	0,973	0,020
M2 Sin sensibles	0,480	0,696	0,986	0,032
M3 Reweighing	0,471	0,685	0,992	0,062
M4 ThresholdOpt	0,432	n.d.	0,919	0,188

- Reweighing logra la mayor paridad, pero empeora el equalized odds por sexo (0,153).
- ThresholdOptimizer **no generalizó**: solo 30 jóvenes en prueba.

Incertidumbre y compromiso

- Los intervalos bootstrap al 95 % de la brecha de aprobación llegan hasta cerca de 0,20 en todos los modelos.
- Con 30 jóvenes en prueba no se puede afirmar que un modelo sea estadísticamente más equitativo.
- Calibración, paridad y equalized odds no pueden cumplirse a la vez si las tasas base difieren (Chouldechova, 2017; Kleinberg et al., 2017).



Ética y limitaciones

- Elegir la métrica de equidad es una **decisión normativa**, no solo técnica.
- Usar edad o sexo para decidir puede ser ilícito; usarlos para auditar es buena práctica.
- Los puntajes deben apoyar la decisión de un analista, con canal de apelación y monitoreo continuo.
- Limitaciones: muestra pequeña, datos de 1994 de una sola entidad, sexo derivado de *personal_status*, una sola partición.

Conclusiones y recomendaciones

- El modelo más complejo no siempre es el mejor: XGBoost no superó a la regresión logística.
- El sesgo viene primero de los datos y perjudica sobre todo a jóvenes buenos pagadores.
- Las mitigaciones aproximan la paridad pero **desplazan** el desequilibrio a otras métricas.
- Recomendación: más datos, validación cruzada repetida, mitigación en entrenamiento, costos explícitos y SHAP.

Código y resultados reproducibles: github.com/dev-cristian-rodriguez/modelo-ia-riesgo-crediticio