Modelo de IA para riesgo crediticio: ¿precisión o equidad?

Auditoría y mitigación de sesgos con XGBoost y Fairlearn

Cristian Estiven Rodriguez Benitez

Electiva II: Inteligencia Artificial Avanzada, Unidad 2

Noviembre de 2026

El problema y por qué importa

2

errores distintos

Rechazar a un buen pagador daña a la persona; aprobar a un mal pagador daña a la entidad.

×

escala

Los datos históricos traen desigualdades que un modelo aprende y aplica masivamente.

Alto

riesgo según la UE

El Reglamento de IA clasifica el scoring crediticio como sistema de alto riesgo.

Pregunta: ¿puede un modelo de crédito ser preciso y justo a la vez, y cuánto cuesta corregirlo?

Datos: German Credit y un sesgo de partida

1.000 solicitudes

20 atributos

30 % de impago

Grupo	n	Incumplimiento
≥ 25 años	851	28,1 %
< 25 años	149	**40,9 %**
Hombres	690	27,7 %
Mujeres	310	**35,2 %**

Atributos protegidos: edad (<25 / ≥25) y sexo. Datos de 1994 de un banco alemán: la diferencia es un patrón de esta muestra, no una afirmación sobre las personas.

Metodología y modelos

1 Preprocesar

Imputar, estandarizar y one-hot (61 características), ajustado solo con entrenamiento

2 Particionar

60/20/20 estratificado: 600 · 200 · 200. La prueba se usa una sola vez

3 Ajustar

Búsqueda aleatoria de 60 configuraciones por AUC de validación; umbral que maximiza F1

M0
Modelo simple
Regresión logística

M1
Modelo avanzado
XGBoost

M2
Sin edad ni sexo
sin atributos sensibles

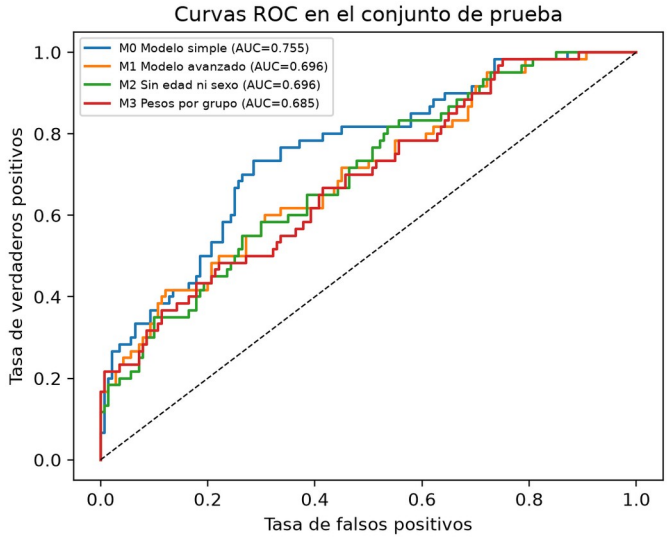
M3
Pesos por grupo
Reweighing

M4
Umbral por grupo
ThresholdOptimizer

Resultados de desempeño

Modelo	Partición	Recall	F1	AUC
M0 Simple	Train	0,767	0,663	0,845
M0 Simple	Test	0,683	0,599	0,755
M1 Avanzado	Train	0,872	0,929	**0,997**
M1 Avanzado	Test	0,417	0,485	0,696

XGBoost se sobreajusta (AUC 0,997 → 0,696) y no supera a la línea base en prueba.



Curvas ROC en el conjunto de prueba

Auditoría de equidad por edad

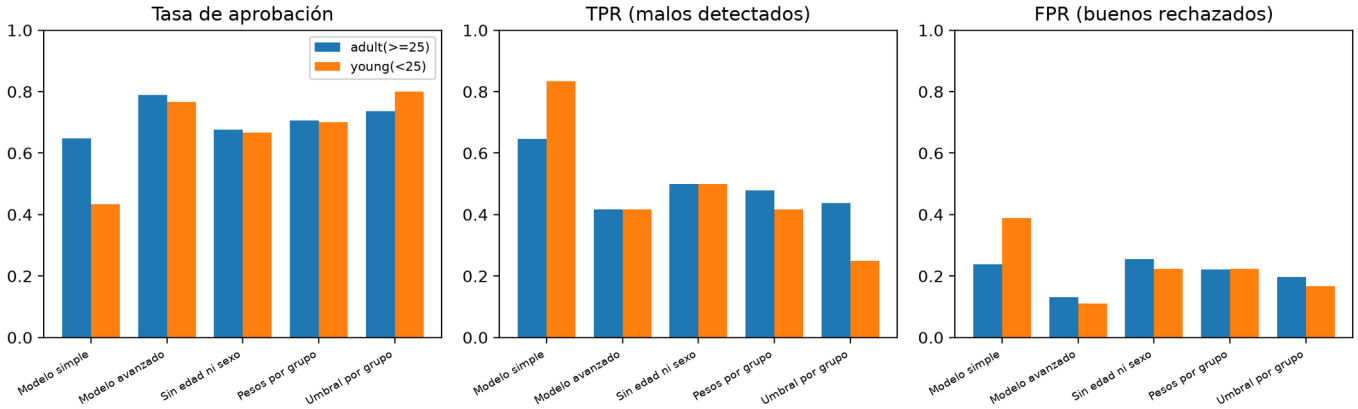
64,7 %

aprobación ≥ 25 años

43,3 %

aprobación < 25 años

La regresión logística tiene un **impacto dispar de 0,67**: incumple la regla de los cuatro quintos (≥ 0,80). Rechaza a más buenos pagadores jóvenes (FPR 0,39 frente a 0,24).



Mitigación de sesgos: lo que cambió

Modelo	F1	AUC	Impacto dispar	EOD edad
M0 Simple (logística)	0,599	0,755	**0,670**	0,188
M1 Avanzado (XGBoost)	0,485	0,696	0,973	0,020
M2 Sin edad ni sexo	0,480	0,696	0,986	0,032
M3 Pesos por grupo	0,471	0,685	0,992	0,062
M4 Umbral por grupo	0,432	n.d.	0,919	0,188

Pesos por grupo (reweighing) logra la mayor paridad, pero empeora el equalized odds por sexo (0,153).

Umbral por grupo no generalizó: solo 30 jóvenes en prueba.

Incertidumbre y compromiso

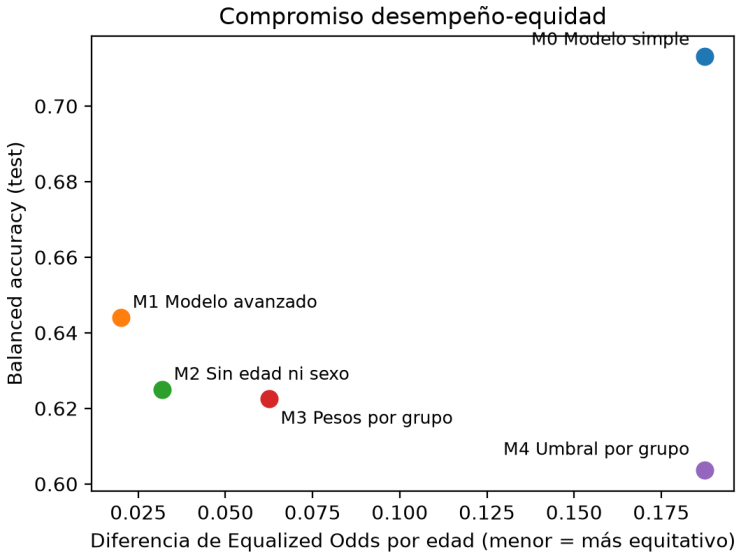
0,20

brecha máxima en el IC bootstrap al 95 %, en todos los modelos

30

jóvenes en prueba: no se puede afirmar que un modelo sea más equitativo

Calibración, paridad y equalized odds no pueden cumplirse a la vez si las tasas base difieren (Chouldechova, 2017; Kleinberg et al., 2017).



Ética y limitaciones

Decisión normativa

Elegir la métrica de equidad no es solo técnico.

Auditar sí, decidir no

Usar edad o sexo para decidir puede ser ilícito; usarlos para auditar es buena práctica.

Humano en el circuito

El puntaje apoya al analista, con canal de apelación y monitoreo continuo.

Limitaciones

Muestra pequeña, datos de 1994 de una entidad, sexo derivado de personal_status, una sola partición.

Conclusiones y recomendaciones

1. El modelo más complejo no siempre es el mejor: XGBoost no superó a la regresión logística.

2. El sesgo viene primero de los datos y perjudica sobre todo a jóvenes buenos pagadores.

3. Las mitigaciones aproximan la paridad pero desplazan el desequilibrio a otras métricas.

4. Recomendación: más datos, validación cruzada repetida, mitigación en entrenamiento, costos explícitos y SHAP.

Código y resultados reproducibles: github.com/dev-cristian-rodriguez/modelo-ia-riesgo-crediticio